

דוח פרויקט - חלק ב': חיזוי דירוגי סרטים באמצעות למידת מכונה (IMDb)

1. תיאור הדאטה המעובד וטבלת הפיצ'רים

בשלב הראשון ביצענו תהליך של ניקוי נתונים וסינון משתנים על גבי קובץ הנתונים המקורי שכולל 133883 שורות ו13 עמודות. מצאנו כי העמודות עם האחוז הכי גבוה של חסרים דאטה הוא: Budget עם 87.64%, BoxOffice עם 86.62%. בחרנו שלא להשתמש בהן במודל שלנו משום שאין מספיק ערכים להתבסס עליהם ואנו עלולים לחזות ערכים לא נכונים. גם עמודת ההכנסות חסרה ברובה, אך לא נשתמש בה במודל משום שהיא מידע שמקבלים לאחר הדירוג. בנוסף, מחקנו את השורות שבהן משתנה המטרה averageRating היה חסר (13.69% מהדאטה), והסרנו שורות כפולות כדי למנוע כפילויות של אותו סרט.

טבלת משתני המודל (הפיצ'רים ההנדסיים):

שם המשתנה בקוד	סוג המשתנה	תיאור הפיצ'ר ופעולת ההנדסה
runtimeMinutes	רציף	אורך הסרט בדקות
movie_age	רציף	גיל הסרט
title_length	רציף	אורך כותרת הסרט
genre_count	binning	מספר הז'אנרים השונים אליהם משויך הסרט
is_drama	binning	אינדיקטור האם הסרט משויך לז'אנר דרמה
is_documentary	binning	אינדיקטור האם הסרט משויך לז'אנר דוקומנטרי
is_comedy	binning	אינדיקטור האם הסרט משויך לז'אנר קומדיה
is_action	binning	אינדיקטור האם הסרט משויך לז'אנר אקשן
is_thriller	binning	אינדיקטור האם הסרט משויך לז'אנר מותחן
is_horror	binning	אינדיקטור האם הסרט משויך לז'אנר אימה
is_romance	binning	אינדיקטור האם הסרט משויך לז'אנר רומנטיקה
is_crime	binning	אינדיקטור האם הסרט משויך לז'אנר פשע
is_english	binning	אינדיקטור האם שפת המקור של הסרט היא אנגלית

2. סעיף prepare_data ותיעוד השלבים

כדי להכין את הנתונים לאימון המודל, פיתחנו פונקציה מרכזית בשם prepare_data. פונקציה זו מבצעת סדרה של פעולות לניקוי, סינון והנדסת פיצ'רים.

התחלנו בלהפוך את המשתנים startYear ו runtimeMinutes לערכים מספריים, ולמחוק נתונים לא הגיוניים (כמו שנה לפני 1895 או אחרי 2024, וסרטים שקצרים מ-60 דקות או ארוכים מ-300 דקות) על ידי המרתן לערכים חסרים.

בהמשך הסרנו עמודות שלא תרמו לחיזוי או שלא היו רלוונטיות למודל, כגון מזהה הסרט, תקציב, הכנסות, מספר הצבעות, תקציר העלילה ומדינת המקור. בנוסף, הוסרו שורות שבהן ערך היעד (averageRating) היה חסר, וכן הוסרו רשומות כפולות.

לאחר ניקוי הנתונים יצרנו מספר משתנים חדשים מתוך המידע הקיים:

- movie_age, גיל הסרט, המחושב לפי ההפרש בין השנה הנוכחית לשנת יציאת הסרט.
- title_length, אורך שם הסרט במספר תווים.
- genre_count, מספר הז'אנרים המשויכים לכל סרט.
- is_english, משתנה בינארי (0 או 1) המציין האם שפת הסרט היא אנגלית.

בנוסף, יצרנו משתנים בינאריים עבור הז'אנרים הנפוצים ביותר (Drama, Documentary, Comedy) המתאים ו-0 אחרת.

לבסוף, הסרנו את העמודות הטקסטואליות המקוריות ווידאנו שהדאטה מכיל אך ורק משתנים מספריים ובינאריים שמתאימים ישירות לאימון המודלים.

3. השוואת ביצועי המודלים (באימות צולב CV-10 Fold)

חילקנו את הדאטה שלנו ל-80% קבוצת אימון (בשביל ללמד את המודל) ו-20% קבוצת מבחן (לבדיקה הסופית). כדי לבדוק את המודלים בצורה הכי אמינה, עשינו על קבוצת האימון תהליך מחלקים את הנתונים ל-10 חלקים שווים. בכל פעם המודל לומד מתוך 9 חלקים, ונבדק על החלק ה-1 שנשאר בצד. התהליך הזה חוזר על עצמו 10 פעמים, ובסוף מחשבים את ממוצע התוצאות. שיטה זו מאפשרת לקבל הערכה יציבה ואמינה יותר של ביצועי המודל ומפחיתה את התלות בחלוקה אקראית אחת של הנתונים. בזמן האימון השתמשנו ב Pipeline שביצע באופן אוטומטי השלמת ערכים חסרים (Imputation) ונרמול של המספרים (Scaling). עבור מודל ה ElasticNet, הרצנו גם Grid Search כדי למצוא את ההגדרות הטובות ביותר עבורו.

כדי לדעת איזה מודל הכי מדויק, בדקנו שלושה מדדים:

RMSE ו MAE : מדדים המראים את גודל הטעות של המודל (ככל שהמספר נמוך יותר, המודל טוב יותר).

R^2 : מדד המראה עד כמה המודל מצליח להסביר את השונות בנתונים (ככל שהאחוז גבוה יותר, המודל טוב יותר).

תוצאות הבדיקות הם :

מודל	RMSE	MAE	R^2
Elastic Net	1.1418	0.8765	0.2216
Random Forest	1.1189	0.8533	0.2524

ניתן לראות כי מודל Random Forest השיג את הביצועים הטובים ביותר בכל המדדים. ערכי ה-RMSE וה-MAE שלו נמוכים יותר, כלומר שגיאות החיזוי קטנות יותר, וערך ה- R^2 שלו גבוה יותר, ולכן הוא מצליח להסביר חלק גדול יותר מהשונות בדירוגי הסרטים. לאור תוצאות בחרנו Random Forest כמודל הסופי של הפרויקט.


4. ניתוח חשיבות פיצ'רים (Feature Importance)

לאחר בחירת מודל ה Random Forest כמודל המוביל, חילצנו מתוכו את מדד חשיבות המשתנים (Feature Importance) כדי להבין אילו מאפיינים משפיעים הכי הרבה על דירוג הסרט.

חמשת המשתנים המשפיעים ביותר:

דירוג	שם המשתנה	רמת השפעה	משמעות המשתנה
1	runtimeMinutes	21.49%	אורך הסרט בדקות
2	is_documentary	20.46%	האם הסרט דוקומנטרי
3	movie_age	16.60%	גיל הסרט מאז יציאתו
4	is_horror	14.03%	האם הסרט שייך לז'אנר האימה
5	title_length	11.95%	אורך שם הסרט במספר תווים

ניתן לראות כי אורך הסרט (runtimeMinutes) הוא המשתנים המשפיע ביותר על דירוג הסרט במודל. בנוסף, מאפיינים הקשורים לז'אנר הסרט, כגון Documentary, Horror, מופיעים בין המשתנים החשובים ביותר, דבר המעיד כי לסוג הסרט יש השפעה משמעותית על הדירוג הצפוי. כדי להבין טוב יותר כיצד המודלים מקבלים החלטות, ביצענו גם השוואה בין המשתנים החשובים ביותר של Random Forest ושל Elastic Net.



מהגרף ניתן לראות ששני המודלים מסכימים שאורך הסרט (runtimeMinutes) והז'אנר דרמה (is_drama) הם משתנים חשובים מאוד לחיזוי דירוג הסרט. כלומר, לשני המאפיינים האלה יש השפעה אמיתית על הציון, בלי קשר למודל שבו משתמשים.

יחד עם זאת, קיימים ביניהם הבדלים מעניינים שנובעים מהדרך שבה כל מודל עובד באופן פנימי. מודל Elastic Net מחפש קשרים ישירים ופשוטים (ליניאריים), ולכן הוא מדגיש משתנים כמו סרט דוקומנטרי (is_documentary) או סרט אימה (is_horror). לעומתו, מודל Random Forest מחפש קשרים מורכבים יותר (לא-ליניאריים), ובגלל שהוא עובד בשיטה של פיצולים ותנאים, הוא מצליח לזהות חשיבות גם במשתנה כמו אורך שם הסרט (title_length). בנוסף, ניתן לראות ש-Random Forest נותן משקל גבוה יותר לאורך הסרט בהשוואה ל-Elastic Net; זה קורה מפני שהקשר בין אורך הסרט לציון שלו הוא מורכב, ומודל מבוסס עצים יודע לזהות נקודות חיתוך חכמות שהמודל הליניארי הפשוט מפספס. לסיכום, שני המודלים מסכימים על הגורמים העיקריים שקובעים את הציון, אבל מודל Random Forest מנצל הרבה יותר טוב את הקשרים המורכבים ואת השילובים בין המשתנים בדאטה, וזו בדיוק הסיבה שהוא השיג תוצאות מדויקות וטובות יותר.

5. ניתוח שגיאות (Error Analysis)

5.1 ניתוח חריגים (Outliers)

בסעיף זה בדקנו את 20 הטעויות הגדולות ביותר של המודל: 10 סרטים שקיבלו תחזית גבוהה מדי ביחס למציאות (Overprediction) ו-10 סרטים שקיבלו תחזית נמוכה מדי (Underprediction).

סרטים שקיבלו ציון גבוה מדי מהמציאות (Overprediction):

- At the Back of the Screen (חזוי: 7.61, בפועל: 1.5)

זהו סרט תיעודי ארוך במיוחד (188 דקות). המודל למד שסרטים תיעודיים ארוכים נוטים לקבל דירוגים גבוהים, ולכן חזה לסרט ציון גבוה. בפועל, המודל אינו מסוגל להעריך גורמים כמו איכות העריכה או חוויית הצפייה, ולכן טעה באופן משמעותי.

- Halloween Deluxe (חזוי: 5.10, בפועל: 1.3)

מדובר בפרויקט Fan-Edit של שני סרטי אימה מוכרים. המודל זיהה סרט אימה ארוך במיוחד ולכן העריך שהוא יקבל דירוג גבוה יחסית. עם זאת, הוא לא ידע שמדובר בעריכת מעריצים ולא בהפקה קולנועית רשמית, ולכן העריך את איכותו ביתר.

סרטים שקיבלו ציון נמוך מדי מהמציאות (Underprediction):

- Afterthought (חזוי: 4.48, בפועל: 9.0)

המודל ניחש לסרט ציון נמוך כי הוא קצר ובז'אנר אימה. אבל כשבדקנו את הנתונים המקוריים, גילינו שרק 9 אנשים הצביעו לו והם כנראה מאוד אהבו אותו ולכן נתנו לו ציון גבוה. בגלל שמחקנו מהמודל את כמות ההצבעות המודל לא יכול היה לדעת שמדובר בסרט קטן עם קבוצת מעריצים קרובה.

- Son-nim-1 Cheo-beon-jjae I-ya-gi (חזוי נמוך, בפועל גבוה)

זהו סרט אימה קוריאני עם שם ארוך ומיוחד. המודל לא יכול להבין את התרבות הקוריאנית או אם הסיפור של הסרט באמת טוב ומעניין, ולכן הוא ניחש לו ציון נמוך בהרבה מהציון שהוא קיבל במציאות.

אפשר להבין מהניתוח הסרטים החריגים, שאם בדאטה אין מידע על איכות ההפקה, השם של היוצרים, כמות המצביעים או מאפיינים תרבותיים, המודל פשוט מתקשה לתת תחזית מדויקת.

2. 5. זיהוי דפוסים משותפים בטעויות

כשבדקנו את הטעויות ראינו כמה דפוסים שחוזרים על עצמם:

אורך שם הסרט: (title_length) בסרטים שהמודל צדק בהם, אורך השם היה בערך 16 אותיות. לעומת זאת, בסרטים שהמודל טעה בהם, השמות היו הרבה יותר ארוכים. זה מראה שהמודל פשוט מתבלבל משמות ארוכים או מורכבים מדי.

אורך הסרט: (runtimeMinutes) ראינו שהמודל נוטה לטעות לטובת סרטים ארוכים. בסרטים שהמודל נתן להם ציון גבוה מדי מהמציאות משך הסרט היה ארוך מהממוצע. נראה שהמודל חושב שאם סרט הוא ארוך. הוא בהכרח טוב יותר, ולכן הוא נותן לפעמים ציונים גבוהים מדי לסרטים ארוכים.

סוג הסרט (הז'אנר והשפה): המודל נוטה לתת ציונים נמוכים מדי מהמציאות לסרטי פעולה ומתח. ייתכן שהוא פשוט מתקשה להעריך דברים שלא כתובים במספרים, כמו קצב, מתח, אפקטים או כמה הסרט פופולרי בקרב הקהל. בנוסף, המודל כמעט אף פעם לא נתן ציונים נמוכים מדי לסרטים באנגלית, מה שמראה שהוא קצת "מעדיף" אותם.

לסיכום, טעויות המודל אינן אקראיות אלא נובעות מהטיות שיטתיות. קבוצת ה Overprediction מאופיינת בנטייה להערכת יתר של סרטים בעלי מאפיינים טכניים מסוימים, בעוד שקבוצת ה Underprediction מאופיינת בעיקר בסרטי פעולה ומותחן.

5.3 השוואה בין המודלים

השווינו את 20 הטעויות הגדולות ביותר של שני המודלים Random Forest Elastic Net וגילינו כי 14 מתוך 20 הסרטים הופיעו ברשימת החריגים של שני המודלים גם יחד. ממצא זה מצביע על כך שרוב הטעויות אינן נובעות מסוג האלגוריתם, אלא ממידע חסר בדאטה עצמו. סרט שהיה קשה לחיזוי עבור מודל אחד, היה לרוב קשה לחיזוי גם עבור המודל השני. עם זאת, מודל Random Forest השיג ביצועים טובים יותר באופן כללי, משום שהוא מסוגל לזהות קשרים מורכבים ולא-ליניאריים שהמודל הליניארי (Elastic Net) מתקשה ללכוד.

5.4 הצעות לשיפור המודל בעתיד

ניתוח השגיאות מראה שהדרך הכי טובה לשפר את המודל היא לא להחליף את האלגוריתם, אלא להוסיף לו נתונים (פיצ'רים) חדשים. שיפור אחד יכול להיות הוספת מידע על איכות ההפקה, כמו תקציב הסרט, השחקנים הראשיים או השם של הבמאי. המידע הזה יעזור למודל להבדיל בין סרט

איכותי לסרט חובבים, במיוחד כשהנתונים הטכניים היבשים לא מספרים את כל הסיפור. בנוסף, כדאי ליצור משתנה חדש שמשלב בין סוג הסרט (הז'אנר) לבין האורך שלו. שילוב כזה יסביר למודל שאורך 'טוב' משתנה בין סוגי סרטים. משתנה כזה ימנע הרבה מהטעויות של המודל.

רוב הטעויות קורות פשוט כי חסר מידע בדאטה, ולא בגלל שהאלגוריתם לא טוב. לכן, הוספת מידע חדש ורלוונטי תעזור למודל הרבה יותר מאשר להחליף את האלגוריתם עצמו.

6. ניתוח הוגנות (Fairness Analysis)

מטרת ניתוח ההוגנות היא לבדוק האם המודל מציג רמת דיוק דומה עבור סוגים שונים של סרטים, או שישנן קבוצות מסוימות שבהן הביצועים שלו חלשים יותר. במסגרת הניתוח בדקנו את ביצועי מודל ה Random Forest עבור קבוצות שונות של סרטים לפי ז'אנר, שפת הסרט ועשור היציאה. לצורך ההשוואה השתמשנו במדדי השגיאה MAE ו-RMSE.

6.1 האם קיימים חתכים שבהם המודל פחות מדויק?

הוגנות לפי ז'אנר:

ז'אנר	RMSE	MAE
Drama	1.059	0.807
Comedy	1.132	0.867
Documentary	1.000	0.736
Romance	1.021	0.775

ניתן לראות כי המודל מדויק יחסית עבור סרטים דוקומנטריים ורומנטיים, בעוד שבסרטי קומדיה השגיאה גבוהה יותר. לדוגמה, ערך ה MAE עבור סרטי קומדיה גבוה כ-18% בהשוואה לסרטים דוקומנטריים (0.867 לעומת 0.736). אחת הסיבות האפשריות לכך היא שסרטים דוקומנטריים מאופיינים לעיתים במאפיינים ברורים יותר, בעוד שהצלחתם של סרטי קומדיה תלויה בגורמים סובייקטיביים יותר כגון חוש הומור, העדפות קהל והקשר תרבותי, מידע שאינו מופיע בדאטה.

הוגנות לפי תקופת יציאה:

עשור	RMSE	MAE
1980s	1.068	0.837
1990s	1.074	0.835
2000s	1.147	0.876
2010s	1.180	0.895
2020s	1.256	0.958

ניתן לראות כי דיוק המודל יורד באופן עקבי ככל שהסרטים חדשים יותר. סרטים משנות ה-2020 מציגים את השגיאה הגבוהה ביותר, כאשר ערך ה MAE-גבוה בכ-15% בהשוואה לסרטים משנות ה-1980. הסבר אפשרי לכך הוא שסרטים חדשים מושפעים מטרנדים משתנים, שינויים בטעם הקהל ופלטפורמות צפייה חדשות, בעוד שהדאטה הזמין למודל כולל בעיקר מאפיינים בסיסיים כגון אורך הסרט, גיל הסרט והז'אנר. בנוסף, ייתכן שדירוגים של סרטים חדשים עדיין אינם יציבים ומשתנים עם הזמן.

6.2. האם יש הסבר לפערים אלו?

הסיבה הראשונה והכי חשובה היא שמחקנו מהדאטה משתנים קריטיים כמו תקציב הסרט, ההכנסות שלו בקופות וכמות ההצבעות שהוא קיבל, בגלל שהיו חסרים בהם המון נתונים. המחיקה הזו גרמה למודל לאבד מידע יקר שיכול היה לספר לו על איכות ההפקה ועל רמת הפופולריות של הסרט. סיבה שנייה היא שלסרטים חדשים משנות ה-2020 יש חוקים משלהם, והם מושפעים מאוד מטרנדים ברשתות החברתיות, מפלטפורמות סטרימינג ומטעם של קהל שמשתנה מהר מאוד. המידע הדינמי הזה לא נמצא בדאטה שלנו, ולכן קשה למודל לנחש ציון של סרט חדש רק לפי נתונים יבשים. הסיבה האחרונה קשורה לחוסר איזון בנתונים, כי רוב הסרטים ב IMDb הם באנגלית, ולכן המודל ראה המון דוגמאות כאלו ולמד לנחש אותן מצוין. לעומת זאת, סרטים בשפות זרות הם לעיתים קרובות סרטי נישא או סרטים מקומיים עם תרבות ודפוסי דירוג שונים לגמרי, וזה מקשה על המודל לדייק בהם.

6.3. האם הדבר מעלה חששות לגבי שימוש במודל בפועל?

הממצאים מראים שלא כל התחזיות של המודל אמינות באותה מידה. המודל מציג ביצועים טובים יחסית עבור סרטים דוקומנטריים, סרטים ותיקים וסרטים באנגלית, ולכן ניתן לסמוך יותר על התחזיות עבור קבוצות אלו. לעומת זאת, יש להתייחס בזהירות לתחזיות עבור סרטי מתח, קומדיה וסרטים חדשים משנות ה-2020, שבהם רמת השגיאה גבוהה יותר. בניתוח החריגים ראינו כי סרטים מסוג זה הופיעו פעמים רבות בקבוצת השגיאות הגדולות, ולכן המודל מתקשה לחזות אותם בצורה עקבית. לכן, אם המודל היה משמש במערכת אמיתית להערכת הצלחת סרטים, היינו רואים בו כלי עזר לקבלת החלטות ולא כלי שניתן להסתמך עליו באופן בלעדי.

6.4. האם קיימת הטיה (Bias) במודל?

הניתוח שלנו מראה שיש במודל כמה הטיות קבועות שמשפיעות על הניחושים שלו. הטיה אחת ברורה קשורה לז'אנרים מסוימים, שכן בניתוח החריגים והשגיאות הגדולות נצפתה נטייה להערכת חסר עבור סרטי פעולה, מתח ואימה, ככל הנראה בגלל שהוא מתקשה להעריך דברים שלא כתובים במספרים כמו רמת המתח של הסיפור, איכות האפקטים או הפופולריות של הסרט בקרב המעריצים. בנוסף לכך, מצינו שהמודל קצת מעדיף סרטים באנגלית, והוא כמעט אף פעם לא נתן להם ציונים נמוכים מדי מהמציאות, בעוד שסרטים בשפות זרות הופיעו הרבה יותר ברשימת הטעויות הגדולות, וזה קורה פשוט בגלל שרוב הסרטים בדאטה המקורי הם באנגלית. לסיכום, למרות ההטיות האלו, המודל עדיין מציג רמת הוגנות כללית טובה ואין בו כשלים חמורים, כאשר כדי לשפר אותו בעתיד לא צריך להחליף את האלגוריתם, אלא פשוט להוסיף מידע חדש ואיכותי כמו תקציב הסרט, השחקנים הראשיים, השם של הבמאי או משתנה משולב שמחבר בין הז'אנר לאורך הסרט.

7. מניעת זליגת נתונים (Data Leakage) ומהימנות המודל

בפרויקט הזה עשינו כמה דברים חשובים כדי למנוע זליגת נתונים, כדי להיות בטוחות שהתוצאות של המודל אמיתיות ושהוא לא מרמה או משתמש במידע שלא אמור להיות לו במציאות. הדבר הראשון שעשינו היה למחוק מהדאטה משתנים בעייתיים, ובעיקר את כמות ההצבעות. המשתנה הזה קשור ישירות לפופולריות של הסרט והוא נאסף רק אחרי שהסרט כבר יצא לאקרנים, ולכן אם היינו משאירות אותו, המודל היה מנחש ציונים לפי מידע שפשוט לא קיים כשרוצים לבדוק סרט חדש לגמרי. מאותה סיבה בדיוק מחקנו גם את עמודת ההכנסות בקופות כי הנתונים הכספיים האלו

מגיעים רק אחרי שהסרט כבר יצא לקולנוע והצליח, וזה מידע שאי אפשר להשתמש בו בתרחיש חיזוי אמיתי.

הדבר השני שעשינו היה להפריד את הנתונים לקבוצת אימון וקבוצת מבחן עוד לפני שנגענו בהם או עשינו שינויים כלשהם. כדי לשמור על הכלל הזה בצורה הכי מחמירה, הכנסנו את כל השלבים של השלמת הנתונים החסרים והנרמול לתוך תהליך אוטומטי אחד שנקרא Pipeline. המשמעות היא שכל מדד סטטיסטי, כמו חציון, ממוצע או סטיית תקן, חושב אך ורק על סמך קבוצת האימון ולא על סמך כל הדאטה רק לאחר מכן המודל השתמש בהם כדי לבדוק את נתוני המבחן. שמרנו על העיקרון הזה גם כשעשינו את תהליך ה-Fold Cross Validation-10, ובדקנו שבכל אחד מהשלבים המודל לא רואה אפילו רמז מהמידע של קבוצת הבדיקה. כל הצעדים האלו עצרו זליגת מידע והבטיחו שהמודל באמת יודע להתמודד בצורה אמينة עם סרטים חדשים שהוא מעולם לא ראה.

8. מסקנות, מגבלות והצעות להמשך

בפרויקט זה פיתחנו מודל למידת מכונה לחיזוי דירוגי סרטים על בסיס מאפיינים מתוך מאגר IMDb. לצורך כך ביצענו ניקוי נתונים, הנדסת פיצורים, השוואה בין מודלים שונים וניתוח מעמיק של ביצועיהם. השוואת המודלים הראתה כי מודל Random Forest השיג את הביצועים הטובים ביותר מבין המודלים שנבחנו, עם ערכי שגיאה נמוכים יותר ויכולת הסבר גבוהה יותר בהשוואה למודל Elastic Net. עם זאת, גם המודל הטוב ביותר הצליח להסביר רק חלק מהשונויות בדירוגי הסרטים ($R^2 \approx 0.25$), דבר המעיד כי דירוג של סרט מושפע במידה רבה גם מגורמים איכותניים שאינם מופיעים בדאטה. ניתוח חשיבות המשתנים הראה כי אורך הסרט (runtimeMinutes), אורך שם הסרט (title_length) והז'אנר של הסרט הם בין המשתנים המשפיעים ביותר על החיזוי. בנוסף, ניתוח השגיאות וההוגנות הראה כי המודל מתקשה במיוחד בחיזוי סרטים חדשים משנות ה-2020 ובחלק מהז'אנרים, כגון קומדיה ומתח. לצד ההצלחות, קיימות מספר מגבלות משמעותיות למודל. אחת המגבלות המרכזיות היא שהמודל "עיוור" למאפיינים איכותניים רבים המשפיעים על הצלחת הסרט, כגון איכות המשחק, זהות הבמאי, התוכן הוויזואלי, איכות התסריט והעלילה עצמה. בנוסף, עמודת ה-plot לא נכללה במודל, ועמודות כמו BoxOffice הוסרו בשל איכות נתונים נמוכה או חוסר התאמה לתרחיש חיזוי אמיתי. כמו כן, עמודת numVotes לא נכללה במודל בהתאם להנחיות הפרויקט ולחשש ל-Data Leakage. כתוצאה מכך, המודל נאלץ לקבל החלטות על בסיס מידע חלקי בלבד. בעתיד ניתן לשפר את המודל באמצעות שילוב מקורות מידע נוספים והוספת פיצורים חדשים, כגון מידע על במאים, שחקנים מובילים, חברות הפקה ומאפיינים נוספים של הסרט. בנוסף, ניתן לבחון יצירת משתני אינטראקציה חדשים בין מאפיינים שונים של הסרט, וכן להשתמש בשיטות של עיבוד שפה טבעית (NLP) לצורך ניתוח תקצירי עלילה, ביקורות או מידע טקסטואלי אחר. שילוב מידע כזה עשוי לאפשר למודל לזהות מאפיינים איכותניים שאינם מיוצגים כיום בדאטה ולשפר את יכולת החיזוי שלו. תוצאות אלו מדגישות כי הצלחתו של מודל למידת מכונה תלויה לא רק בבחירת האלגוריתם, אלא גם באיכות הנתונים ובפיצורים הזמינים לאימון. לסיכום, למרות מגבלותיו, המודל הצליח לזהות דפוסים משמעותיים בדאטה ולהפיק תחזיות ברמת דיוק סבירה. שילוב מידע עשיר ומגוון יותר צפוי לשפר משמעותית את ביצועי המודל בעתיד.

9. יומן שימוש בבינה מלאכותית (AI Usage Log)

- כלי ה-LLM בשימוש: Google Gemini
- מטרת השימוש: סיוע בניתוח הקוד, חילוץ מדדי הביצוע מתוך האאוטפוט של ה-Notebook